# 논문 스터디 보조 GPT 설계 및 구현 보고서

*프롬프트 엔지니어링 기반 **논문** 추천 · 읽기 가이드 에이전트*

거대언어모형 2026311564 이우준

## 1. 서론: 이 모델을 만들게 된 계기

동기들끼리 논문 스터디를 하다 보면 공부를 하여 발표를 할 논문을 선정해야 하는 일이 생기는데, 실제 병목은 "읽기"보다 "무엇을 읽을지 고르는 일"에서 가장 크게 발생한다는 것을 계속 느끼고 있었다. 관심 분야가 막연할 때는 검색어를 정하는 것부터 어렵고, 키워드를 정하더라도 검색 결과에는 고전 논문, 최신 벤치마크, 튜토리얼 성격의 논문, 이론 중심 논문, 구현 중심 논문이 한꺼번에 섞여 나온다. 결국 사용자는 주제 적합성, 난이도, 발표 시기, 저명성, 분량을 동시에 고려해야 하며, 이 과정이 생각보다 오래 걸리게 되는 것이다.

더 큰 문제는 논문 한 편을 시작하는 데 드는 기회비용이 크다는 점이다. 한 편을 제대로 읽기 시작하면 수 시간에서 수 일이 필요하고, 배경지식이 부족하면 더 오래 걸린다. 그래서 "지금 읽을 가치가 있는가", "너무 어렵지 않은가", "이미 읽은 논문과 지나치게 겹치지 않는가", "필수적으로 짚고 넘어가야 할 유명한 논문인가"를 매우 신중하게 따지게 된다. 즉, 대학원생에게는 논문 읽기만큼이나 **논문 선택**이 중요한 연구 역량임을 모두가 알고 있다.

이 프로젝트는 이러한 문제를 해결하기 위해 설계되었다. 목표는 단순 검색 결과 나열이 아니라, 사용자의 관심 키워드, 이전 독서 이력, 원하는 난이도, 최신성 선호를 함께 반영하여 **지금 읽어야 할 논문 후보를 추천하고**, 사용자가 하나를 선택하면 **왜 읽어야 하는지와 어떻게 읽어야 하는지**까지 안내하는 연구 보조 GPT 를 구현하는 것이다.

## 2. 과제 설명과의 부합성

본 프로젝트는 과제 설명 중 **주제 2: LLM 을 활용한 (전공) 연구 보조 파이프라인 구축 및 평가**에 가장 직접적으로 부합한다. 입력-검색-점수화-추천-읽기 가이드 생성까지의 흐름을 하나의 파이프라인으로 실제 구현했기 때문이다. 동시에 특정 업무(문헌 탐색·스터디 준비)에 최적화된 구조를 가지므로 **주제 3: 전공 특화 GPTs 개발 프로젝트**의 성격도 함께 가진다.

평가 항목과의 대응을 살펴보면,

- 개념 연계: Prompt Engineering, LLM, AI Design & Control, Responsible AI 반영
- 결과물 완성도: VS Code 에서 바로 실행 가능한 코드와 산출물 저장 구조 제공
- 비판적 성찰: 환각, 인용 수 편향, 본문 미분석 한계를 명시
- 논리적 구성: 문제 정의 → 설계 → 구현 → 활용 → 한계 순으로 정리 가능

## 3. 시스템 원리와 기술, 그리고 구조

본 시스템은 **하이브리드 추천 구조**를 사용한다. 1 차로는 학술 API 검색 결과를 점수화하여 후보를 안정적으로 압축하고, 2 차로는 LLM 이 상위 후보를 재정렬하며 추천 사유와 읽기 가이드를 생성한다. 즉, "LLM 에게 전부 맡기는 구조"가 아니라 **검색 + 점수화 + 구조화 프롬프트 + human-in-the-loop** 를 결합한 시스템이다.

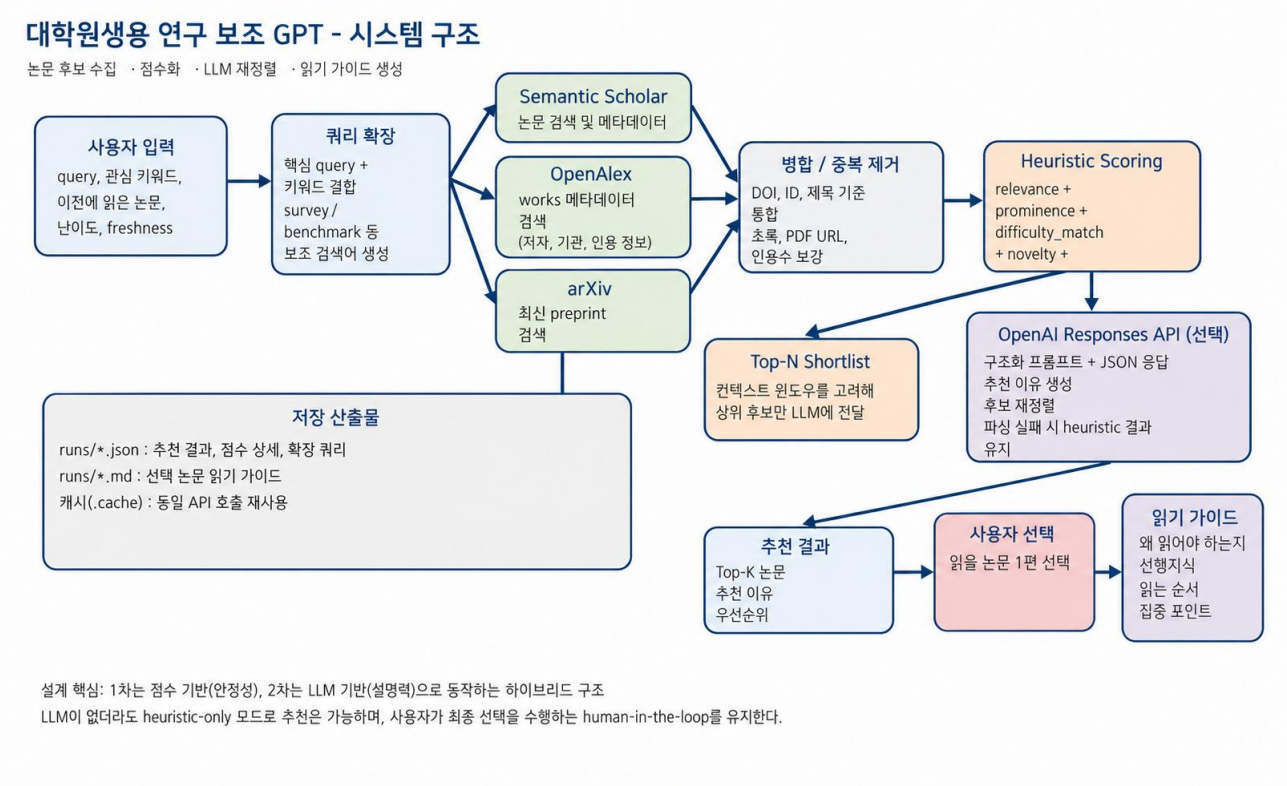


*그림 1. 대학원생용 연구 보조 GPT 의 전체 구조*

사용한 핵심 기술은 다음과 같다.

- **Semantic Scholar Academic Graph API**: 제목, 초록, 연도, 저자, venue, citation count, influential citation count, TLDR 등 **논문 메타데이터** 수집 [API1]
- **OpenAlex Works API:** 학술 works **메타데이터** 보강 [API2]
- **arXiv API**: 최신 preprint 보강 [API3]
- **OpenAI Responses API(GPT-5.4-mini, 모델은 자유)**: 구조화 프롬프트 기반 **추천 이유** 생성 및 **논문 읽기 가이드** 생성 [API4]

**추천 점수**는 아래 다섯 요소를 함께 고려한다.

- **관련성**(relevance): query 와 키워드가 제목·초록·분야와 얼마나 맞는가
- **저명성**(prominence): citation count, influential citation count, citation velocity
- **난이도 적합도**(difficulty match): beginner/intermediate/advanced 목표와의 차이
- **새로움**(novelty): 이전에 읽은 논문과 얼마나 덜 겹치는가

- **최신성**(freshness): classic / balanced / latest 선호 반영

구현상 **최종 점수**는

`0.42*relevance + 0.24*prominence + 0.16*difficulty_match + 0.10*novelty + 0.08*freshness`

로 계산한다. survey, tutorial, review 같은 입문 친화적 단서는 non-advanced 사용자에게 소폭 가산점으로 반영한다.

## 4. 핵심 기능 상세: 프롬프트에 따라 시스템이 어떻게 동작하는가

### 4.1 입력 단계

사용자는 `query`, `interest_keywords`, `read_papers`, `difficulty_target`, `freshness_mode`를 입력한다. 이 정보는 `**UserProfile**`로 정리되어 이후 추천 전 과정의 기준이 된다.

즉, 이 시스템은 단발성 질문이 아니라 **누적형 연구 프로필**을 전제로 설계되어 있다.

### 4.2 쿼리 확장 단계

`expand_queries()`는 원문 query 만 쓰지 않고, 관심 키워드를 결합하거나 `survey`, `benchmark`, `foundational`, `recent` 같은 표현을 추가해 **보조 질의**를 만든다. 같은 관심사라도 검색 표현에 따라 결과가 크게 달라질 수 있기 때문이다.

### 4.3 논문 수집 단계

확장 query 는 세 클라이언트로 전달된다.

1. `SemanticScholarClient.search_papers()`
2. `OpenAlexClient.search_papers()`
3. `ArxivClient.search_papers()`

이후 `merge_papers()`가 DOI(디지털 고유 식별번호), API ID, 제목 기준으로 중복을 제거하고, 초록·PDF URL·venue·연도 등을 상호 보강한다. 또한 `CachedSession`을 두어 동일 요청은 캐시에 저장하므로 반복 사용 시 응답 속도를 개선한다.

### 4.4 점수화 단계

`rank_papers()`는 논문마다 다음을 계산한다.

- relevance: query 토큰과 제목/초록/분야 토큰 겹침
- prominence: 인용 수와 영향 인용 수, citation velocity 기반 점수
- difficulty: title/abstract 힌트와 초록 길이, 일부 venue 특성으로 추정
- novelty: 이전에 읽은 논문과의 유사도 기반 중복 억제
- freshness: 최신성 또는 고전성 선호 반영

이 단계는 LLM 이 없어도 일관되게 동작하는 **안정 장치**다.

### 4.5 추천 프롬프트 설계

LLM 추천 단계는 단순 질의가 아니라 아래와 같은 구조화 프롬프트를 사용한다.

- Context: 현재 질문, 관심 키워드, 이전 독서 이력, 난이도, freshness 모드
- Objective: must-read 논문 Top-K 선택
- Selection Rules: 관련성, 저명성, 난이도, 새로움의 균형
- Style/Tone/Audience
- Response: JSON only
- Few-shot Example

LLM 은 shortlist 만 받아 각 후보의 `reason`, `fit_summary`, `reading_priority`, `expected_takeaway`, `difficulty_note`를 생성한다. JSON 파싱이 실패하면 heuristic 결과를 유지한다. 즉, 설명력은 LLM 이 담당하되, 실패해도 시스템은 무너지지 않는다.

### 4.6 논문 분석 프롬프트 설계

사용자가 논문 하나를 선택하면 분석 프롬프트가 다시 실행된다. 여기서는 다음을 생성한다.

- 짧은 summary
- 왜 읽어야 하는지
- 선행지식
- 읽는 순서
- 집중 포인트
- 주의점
- 이전 독서 이력과의 연결

만약 LLM 호출이 실패하면 `_fallback_analysis()`가 메타데이터 중심의 기본 읽기 가이드를 생성한다.

### 4.7 산출물 저장

추천 결과는 `runs/*.json`, 분석 결과는 `runs/*.md`로 저장된다. 따라서 이 시스템은 단순 대화 응답이 아니라 **재사용 가능한 산출물**을 남긴다. GitHub, Notion, 보고서 작성에도 바로 활용 가능하다.

## 5. 강의록과의 연관성

### 5.1 Prompt Engineering

강의에서는 Prompt Engineering 핵심 설계 원칙으로 **목적성, 맥락 제공, 구체성/명확성, 예시 제공, 구조화**를 제시한다. 또한 Zero-shot, Few-shot, Role Prompting, 구조화된 응답 형식, Co-STAR 프레임워크를 다룬다.

본 프로젝트는 이를 거의 그대로 구현에 옮겼다.

- 목적성: “must-read 논문 추천”과 “읽기 가이드 생성”을 분리
- 맥락 제공: 키워드, 이전 독서 이력, 난이도, freshness 모드 반영
- 구체성/명확성: 출력 필드를 세부적으로 지정
- 예시 제공: few-shot JSON 예시 포함
- 구조화: JSON only 응답 강제
- 역할 지정: “senior graduate research mentor”, “paper reading coach”

즉, 이 프로젝트는 Prompt Engineering 강의를 가장 직접적으로 실습형 시스템으로 구현한 사례다.

### 5.2 Large Language Model

강의에서는 LLM 이 입력 토큰을 받아 다음 토큰 확률을 생성하며, 한 번에 처리할 수 있는 정보는 컨텍스트 윈도우 안에 제한된다고 설명한다.

본 시스템이 모든 후보를 한꺼번에 LLM 에 넣지 않고 **Top-N shortlist 후 재정렬** 구조를 사용하는 이유가 바로 여기에 있다. 강의의 개념을 “실제 시스템 설계 제약”으로 반영한 것이다.

### 5.3 AI Design & Control

강의는 **모델 성능과 시스템 성능은 다르다**, 그리고 좋은 AI 시스템은 입력-맥락-출력-검증-피드백 루프를 가져야 한다고 강조한다.

본 프로젝트는 다음 방식으로 이를 반영한다.

- 입력 구조 분리(UserProfile)
- heuristic ranking → LLM re-ranking 의 2 단 구조
- JSON 출력 강제
- 파싱 실패 시 fallback
- 실행 로그 저장
- 사용자 최종 선택(human-in-the-loop)

특히 강의의 “출력 형식이 제각각이면 활용 불가” 시나리오는 본 프로젝트가 왜 출력 포맷 통제를 중요하게 보았는지 설명해 준다.

### 5.4 Responsible AI / Infrastructure

AI Infrastructure 강의는 API, model management, agent, business value 와 함께 Responsible AI Layer 를 데이터 거버넌스, 모델 거버넌스, 보안, 컴플라이언스 차원에서 설명한다.

본 프로젝트는 다음과 같이 축소판 형태의 Responsible AI 원칙을 반영했다.

- metadata only 원칙: 메타데이터 밖 세부 사실은 추정하지 않음
- unknown 처리: 모르는 정보는 모른다고 출력

- human-in-the-loop: 최종 선택은 사용자가 수행
- 로그 저장: 추천 근거 추적 가능
- 다중 소스 활용: 단일 검색 결과 의존 완화

## 6. 실제 사용 가능성, 한계, 개선 방향

본 프로젝트는 아직 정량 평가를 수행한 것은 아니지만, **실사용 가능한 수준의 유틸리티**는 충분히 가진다.

- 실제 학술 API 기반이므로 존재하지 않는 논문을 추천할 위험을 줄임
- 인용 수만이 아니라 관련성, 난이도, 새로움, 최신성을 함께 반영
- OpenAI 키가 없더라도 heuristic-only 모드로 동작
- 캐시와 실행 로그로 반복 사용성 확보
- 사용자가 최종 논문을 선택하므로 추천을 절대화하지 않음

다만 **한계**도 분명하다.

**1. 논문 본문 전체를 읽지 않는 구조라는 한계**

현재 시스템은 주로 제목, 초록, 저자, 발행 연도, 인용 수, 키워드, 일부 메타데이터를 중심으로 논문을 추천한다. 따라서 논문 내부의 **표, 그림, 실험 설정, 세부 알고리즘, ablation study, appendix** 수준까지 들어간 정밀한 설명은 어렵다.

**2. 난이도 추정의 불완전성**

현재 난이도는 논문 길이, 제목/초록의 용어 밀도, 수학적 표현 여부, 저널/컨퍼런스 특성, survey 여부, benchmark 성격 등 여러 단서를 기반으로 추정하는 heuristic 방식에 가깝다.
하지만 실제 논문의 체감 난이도는 훨씬 복합적이다.

예를 들어 다음과 같은 상황이 발생할 수 있다:

- 수식은 많지 않지만 배경지식이 많이 필요한 논문
- 수식은 많아 보여도 설명이 친절해 오히려 읽기 쉬운 논문
- 사용자의 전공 배경에 따라 쉬움/어려움이 크게 달라지는 논문

**3. citation 기반 평가의 구조적 편향**

본 시스템은 저명성(prominence)을 반영하기 위해 citation, influential citation, 출판 venue, 저자 인지도 등의 요소를 활용한다. 이 방식은 고전 논문이나 이미 학계에서 중요성이 검증된 논문을 추천하는 데에는 효과적이다.
그러나 이런 방식은 구조적으로 **최신 논문이나 emerging topic** 을 과소평가할 가능성이 있다.

특히 멀티모달, agent, video generation, efficient reasoning 처럼 변화 속도가 매우 빠른 분야에서는

- 발표된 지 얼마 안 된 논문
- 아직 citation 이 충분히 쌓이지 않은 preprint
- niche 하지만 향후 중요성이 커질 수 있는 연구

가 불리해질 수 있다.
즉, citation 은 "이미 인정받은 중요성"을 보여주는 지표이지, 반드시 "지금 가장 읽어야 할 논문"을 완벽히 보장하는 지표는 아니다.(특히 최근 다뤄진 터보퀀트 같은 논문은 놓칠 가능성이 높음)

**4. 사용자 관심사의 표현 한계**

사용자가 자신의 관심사를 입력할 때, 실제로는 관심사가 아직 충분히 정리되지 않은 경우가 많다.
예를 들어 사용자는 "멀티모달이 궁금하다", "요즘 뜨는 거 보고 싶다", "너무 어려운 건 싫다"처럼 모호한 수준에서 요청할 수 있다.
이 경우 시스템은 이를 검색 가능한 키워드로 확장해 후보를 찾지만, 입력 자체가 애매하면 결과도 다소 넓거나 빗나갈 수 있다.(프롬프트 기반의 한계성)

즉, 이 시스템은 관심사를 정교하게 다듬는 데 도움을 줄 수는 있지만, **불명확한 문제의식을 완전히 자동으로 정의해 주는 수준은 아니다**.
좋은 추천 결과를 얻기 위해서는 사용자의 **최소한의 방향성 제시**가 여전히 중요하다.

**5. 환각과 과잉 해석 가능성**

추천 이유나 읽기 가이드를 LLM 이 자연어로 생성할 때, 표현은 매우 그럴듯하지만 실제 논문 내용보다 약간 과장되거나 일반화된 설명이 나올 가능성이 있다.

따라서 이 시스템의 출력은 **최종 판단이 아니라 보조 의견**으로 받아들여야 하며, 실제 논문 선택 전에는 제목, 초록, 목차, figure 등을 사용자가 직접 다시 확인하는 과정이 필요하다.

**6. 인간 판단이 여전히 필수적이라는 점**

이 시스템은 좋은 후보를 좁히고 읽는 방향을 안내하는 데 강점이 있지만, "어떤 논문이 지금 내 연구에 가장 결정적으로 필요한가"라는 판단까지 완전히 자동화할 수는 없다.
연구에서는 단순히 유명한 논문보다도, 내 문제와 직접 연결되는 논문, 내 구현 수준에서 실제로 참고할 수 있는 논문, 내 발표/과제 목적에 맞는 논문이 더 중요할 수 있다.

따라서 본 시스템은 연구자나 학생의 판단을 대체하는 것이 아니라, **탐색 비용을 줄이고 의사결정을 보조하는 도구**로 이해하는 것이 적절하다.

이 외에 결국 논문을 읽고 분석하여 발표 자료를 만드는 기능은 없기에, 해당 과정도 인간이 필수적으로 수행(부분적 자동화)해야 한다는 점이 한계점으로 작용한다.

**향후 개선 방향**

향후에는 현재 한계점을 보완하기 위해 몇 가지 방향으로 시스템을 확장할 수 있다.

먼저, 제목·초록 중심 추천을 넘어 **PDF 본문 분석 기능**을 추가하면 표, 그림, 실험 설정, ablation study 까지 반영한 더 정밀한 추천과 읽기 가이드가 가능해질 것이다. 또한 현재의 heuristic 기반 난이도 추정을 보완하기 위해, 사용자의 전공 배경, 이전에 읽은 논문, 실제 피드백을 반영하는 **개인화 난이도 추정** 방식으로 발전시킬 필요가 있다.

또한 citation 중심 평가가 최신 논문을 과소평가할 수 있으므로, 발행 연도, preprint 여부, 최근 급부상한 키워드 등을 함께 반영하는 **최신성 보정 로직**이 필요하다. 사용자 입력이 모호한 경우를 줄이기 위해서는, 입문용인지 구현용인지, 고전 논문이 필요한지 최신 논문이 필요한지 등을 되묻는 **대화형 관심사 정제 단계**도 유용할 것이다.

마지막으로, 현재 시스템은 추천과 읽기 가이드에 초점이 맞춰져 있으므로, 향후에는 **citation graph 기반 읽는 순서 제안, BibTeX/APA export, 발표 자료 초안 생성**, 그리고 Streamlit 기반 UI 추가 등을 통해 실제 연구·발표 준비까지 이어지는 보조 도구로 확장할 수 있다.

## 7. 이상적인 테스트 예시

### 7.0 실행 방법

0. .env 파일의 API 키 발급

    OPEN_API_KEY, SEMANTIC_SCHOLAR_API_KEY, OPENALEX_API_KEY 필요
    테스트를 할 때 필요하시다면, woojun827@gmail.com 으로 메일 주시면 개인 키를 드리겠습니다.

1. 디렉토리 이동 및 가상환경 설정

    cd research_paper_agent
    python -m venv .venv

2. 프로젝트 초기설정

    *.₩.venv₩Scripts₩Activate.ps1*
    *pip install -r requirements.txt*
    *copy .env.example .env* (본인의 개인 API 키 받아서 작성해야 함)

3. 실행(대화형 프롬프트)

    *python app.py*

### 7.1 추천용 query

`multimodal large language models for document understanding and image-text reasoning`

### 7.2 권장 키워드

`multimodal learning, vision-language model, image-text alignment, visual instruction tuning, document understanding, multimodal RAG`

### 7.3 권장 설정

- difficulty_target: `intermediate`

- freshness_mode: `balanced`

따로 입력하지 않을시 해당 값들이 Default 로 들어감

### 7.4 history 파일

별도 파일 `history_multimodal_example.json`을 제공한다.

이 파일은 Transformer 와 ViT 정도는 읽어 봤지만, 멀티모달 핵심 논문은 아직 체계적으로 읽지 않은 사용자를 가정한다.

### 7.5 실행 예시(대화형 사용하지 않을시)

```
python app.py recommend  --query "multimodal large language models for document understanding and image-text reasoning"  --history history_multimodal_example.json  --top-k 5  --analyze-rank 1
```

### 7.6 실제 시연(대화형 프롬프트)

**1 차 시연**

```
C:\Users\wooju\Downloads\research_paper_agent\research_paper_agent>python app.py
=== 대학원생용 연구 보조 GPT ===
현재 찾고 싶은 주제/질문: 멀티모달
관심 키워드(콤마로 구분, 비워도 됨): 트랜스포머
원하는 난이도(beginner/intermediate/advanced) [intermediate]: beginner
논문 성향(classic/balanced/latest) [balanced]: classic
추천 개수 [5]: 3

=== 추천 논문 ===

[1] Foundational Models for 3D Point Clouds: A Survey and Outlook
  - Year/Venue: 2025 / arXiv.org
  - Authors: Vishal G. Thengane, Xiatian Zhu, A. Bouzerdoum 외 2명
  - Citations: 11 | Influential: 0
  - Difficulty: beginner | Score: 0.3553
  - Why: 사용자 쿼리인 '멀티모달'과 가장 직접적으로 맞닿아 있고, 초급 난이도이며 설명에 'multiple modalities'와 3D 시각 이해가 명시되어 있어 입문용으로 적합합니다.
  - URL: https://www.semanticscholar.org/paper/1139070c61a690bf98ce81e440293e8d2dc5cf57

[2] Foundational Models Defining a New Era in Vision: A Survey and Outlook
  - Year/Venue: 2023 / arXiv.org
  - Authors: Muhammad Awais, Muzammal Naseer, Salman Siddique Khan 외 5명
  - Citations: 161 | Influential: 8
  - Difficulty: beginner | Score: 0.4831
  - Why: 비전 분야의 foundational models를 다루며, 메타데이터에 'different modalities'를 결합하는 일반적 구조와 학습 목표가 포함되어 있어 멀티모달 기초 이해에 잘 맞습니다.
  - URL: https://www.semanticscholar.org/paper/584ca135b61482fd89247113da87d784f738dbfa
분석할 논문 번호를 선택하세요 (그만하려면 Enter): 2

=== 읽기 가이드 ===
# Paper Reading Guide

## Selected Paper
- **Title**: Foundational Models Defining a New Era in Vision: A Survey and Outlook
- **Year**: 2023
- **Venue**: arXiv.org
- **Authors**: Muhammad Awais, Muzammal Naseer, Salman Siddique Khan 외 5명
- **URL**: https://www.semanticscholar.org/paper/584ca135b61482fd89247113da87d784f738dbfa
- **PDF**: https://arxiv.org/pdf/2307.13721
- **Estimated Difficulty**: beginner
- **Citations**: 161
- **Influential Citations**: 8

## Summary
이 논문은 컴퓨터 비전에서 '파운데이셔널 모델'이 왜 중요한지, 그리고 이들이 비전·텍스트·오디오·깊이 같은 다양한 모달리티를 어떻게 연결하는지 한 번에 훑어볼 수 있는 서베이입니다. 특히 트랜스포머 관심이 있는 학습자에게는, 단순한 구조 이해를 넘어 멀티모달 결합, 학습 목적함수, 프리트레이닝, 프롬프팅까지 연결해서 보는 데 도움이 됩니다.

## Why Read This Paper
- 비전 분야의 파운데이셔널 모델을 '전체 그림'으로 정리한 서베이이므로, 개별 모델보다 큰 흐름을 먼저 잡기에 좋습니다.
- 트랜스포머 관심과 잘 맞는 이유는, 다양한 모달리티를 결합하는 아키텍처 설계를 다루기 때문입니다.
- 학습 목적(contrastive, generative), 데이터셋, 파인튜닝, 프롬프팅 패턴까지 함께 다뤄서 연구 주제를 찾는 데 유용합니다.
- open challenges와 research directions가 포함되어 있어, 다음에 무엇을 읽어야 할지 방향을 잡기 좋습니다.
```

```
## Recommended Prerequisites
- 컴퓨터 비전의 기본 개념: 이미지, 객체, 시맨틱/장면 이해 정도
- 트랜스포머의 기본 개념: attention, encoder-decoder, 멀티모달 입력의 직관
- 지도학습과 사전학습(pre-training), 미세조정(fine-tuning)의 차이
- 대조학습(contrastive)과 생성학습(generative)의 아주 기본적인 의미
- 모달리티라는 용어에 대한 이해: 텍스트, 시각, 오디오, 깊이 등

## Suggested Reading Order
- 1) 제목과 초록을 먼저 읽고, 이 서베이가 '비전 파운데이셔널 모델의 범위와 쟁점'을 정리하는 글임을
 확인합니다.
- 2) 서베이의 목차를 빠르게 훑어, 아키텍처 / 학습 목적 / 데이터셋 / 파인튜닝 / 프롬프팅 / 오픈 챌
린지의 구조를 파악합니다.
- 3) 멀티모달 아키텍처 부분에서 '어떤 모달리티를 어떻게 결합하는가'만 먼저 잡습니다. 세부 모델명보
다 결합 방식에 집중하세요.
- 4) 학습 목적과 프리트레이닝 데이터셋 부분을 읽으며, 모델 성능이 구조만이 아니라 데이터와 목적함
수에 의해 좌우된다는 점을 체크합니다.
- 5) 파인튜닝과 프롬프팅 섹션을 읽고, '재학습 없이 출력이 어떻게 바뀌는가'라는 관점을 정리합니다.
- 6) 마지막으로 open challenges와 research directions를 읽어, 이 분야의 한계와 연구 공백을 메모합
니다.

## What To Focus On
- 'foundational model'이 일반적인 비전 모델과 무엇이 다른지 한 문장으로 정리해 보세요.
- 아키텍처보다 먼저, 왜 멀티모달 결합이 필요한지를 이해하는 데 집중하세요.
- contrastive vs generative 목적의 차이를 '무엇을 배우게 하려는가' 관점에서 비교해 보세요.
- 프롬프팅 패턴을 읽을 때는, 입력 형식이 어떻게 출력 행동을 바꾸는지에 집중하세요.
- 평가와 벤치마킹의 어려움, 실제 세계 이해의 한계, 편향, adversarial vulnerability, interpretabili
ty를 별도로 메모해 두세요.
- 서베이이므로 세부 실험 재현보다 '분류 체계와 개념 지도'를 얻는 것이 목표입니다.

## Caution Points
- 초록과 메타데이터만으로는 각 섹션의 구체적 모델 이름, 비교 실험, 정량 성능은 알 수 없습니다.
- 이 논문은 서베이이므로 새로운 단일 방법의 성능을 주장하는 글로 읽으면 안 됩니다.
- '포괄적'이라는 표현이 있지만, 실제 포함 범위는 논문 본문과 목차를 확인해야 합니다.
- 벤치마킹, 실제 세계 이해, 편향, adversarial 공격, 해석가능성은 문제 제기 수준일 수 있으니 구체적
 해결책이 있는지 본문에서 확인해야 합니다.
- 오디오·깊이 등 여러 모달리티가 언급되지만, 어떤 모달리티가 중심인지 메타데이터만으로는 확정할 수
 없습니다.

## Comparison To Previously Read Papers
이전 읽은 논문이 없으므로 직접 비교는 어렵습니다. 다만, 초보자 기준에서는 개별 모델 논문보다 먼저
읽기 좋은 '지도(map) 역할'의 서베이입니다. 트랜스포머를 이미 알고 있다면, 이 논문은 attention 메커
니즘 자체보다 그것이 멀티모달 비전 시스템에서 어떤 역할을 하는지 확장해서 보는 연습에 적합합니다.


분석 결과 저장: runs\20260425_034757_foundational-models-defining-a-new-era-in-vision-a-survey-an_
analysis.md

[3] Foundational Models in Medical Imaging: A Comprehensive Survey and Future Vision
  - Year/Venue: 2023 / arXiv.org
  - Authors: Bobby Azad, Reza Azad, Sania Eskandari 외 4명
  - Citations: 118 | Influential: 4
  - Difficulty: beginner | Score: 0.4635
  - Why: 의료영상 도메인에서 foundation models를 다루지만, 설명에 다양한 모달리티를 bridge한다고
명시되어 있어 멀티모달 개념을 다른 응용 분야로 확장해 보는 데 유용합니다.
  - URL: https://www.semanticscholar.org/paper/8e5d42f5b98146d0784fe85e29c768a4989e1478

추천 결과 저장: runs\20260425_034715_멀티모달_recommendations.json
```

## 2 차 시연

```
C:\Users\wooju\Downloads\research_paper_agent\research_paper_agent>python app.py
=== 대학원생용 연구 보조 GPT ===
현재 찾고 싶은 주제/질문: multimodal large language models for document understanding and image-te
xt reasoning
관심 키워드(콤마로 구분, 비워도 됨): `multimodal learning, vision-language model, image-text align
ment, visual instruction tuning, document understanding, multimodal RAG`
원하는 난이도(beginner/intermediate/advanced) [intermediate]: intermediate
논문 성향(classic/balanced/latest) [balanced]: balanced
추천 개수 [5]: 3

=== 추천 논문 ===

[1] Visual Genome: Connecting Language and Vision Using Crowdsourced Dense Image Annotations
  - Year/Venue: 2017 / International Journal of Computer Vision
  - Authors: Ranjay Krishna, Yuke Zhu, Oliver Groth 외 9명
  - Citations: 5112 | Influential: 0
  - Difficulty: intermediate | Score: 0.5201
  - Why: 가장 직접적으로 사용자 관심사와 맞습니다. 언어와 비전을 dense image annotations로 연결하
며, 이미지 설명·질문응답 같은 인지적 멀티모달 과제를 다루는 출발점으로 적합합니다.
  - URL: https://openalex.org/W2277195237

[2] VQA: Visual Question Answering
  - Year/Venue: 2015 / arXiv (Cornell University)
  - Authors: Aishwarya Agrawal, Jiasen Lu, Stanislaw Antol 외 4명
  - Citations: 1095 | Influential: 0
  - Difficulty: intermediate | Score: 0.4893
  - Why: 이미지-텍스트 추론의 대표적인 태스크 설정을 보여주는 논문입니다. 사용자의 관심인 image-te
xt reasoning에 매우 직접적이며, 이후 VQA 계열과 문서 VQA 계열을 읽을 기반이 됩니다.
  - URL: https://openalex.org/W2950761309

[3] Foundation models for generalist medical artificial intelligence
  - Year/Venue: 2023 / Nature
  - Authors: Michael Moor, Oishi Banerjee, Zahra Shakeri Hossein Abad 외 4명
  - Citations: 1452 | Influential: 0
  - Difficulty: intermediate | Score: 0.5061
  - Why: 사용자 키워드 중 multimodal learning과 visual-language/LLM 계열 확장에 가장 가까운 최신
논문입니다. 비록 의료 도메인 중심이지만, large foundation model을 다양한 모달리티와 적은 라벨로 쓰
는 관점을 제공해 문서 이해형 멀티모달 RAG나 범용 MLLM 사고방식과 연결됩니다.
  - URL: https://openalex.org/W4365143687

추천 결과 저장: runs\20260425_154756_multimodal-large-language-models-for-document-understanding-_
recommendations.json
분석할 논문 번호를 선택하세요 (그만하려면 Enter): 3

=== 읽기 가이드 ===
# Paper Reading Guide

## Selected Paper
- **Title**: Foundation models for generalist medical artificial intelligence
- **Year**: 2023
- **Venue**: Nature
- **Authors**: Michael Moor, Oishi Banerjee, Zahra Shakeri Hossein Abad 외 4명
- **URL**: https://openalex.org/W4365143687
- **PDF**: https://www.nature.com/articles/s41586-023-05881-4.pdf
- **Estimated Difficulty**: intermediate
- **Citations**: 1452
- **Influential Citations**: 0

## Summary
이 논문은 의료 AI를 '특정 과제용 모델'에서 '여러 의료 모달리티와 과제를 폭넓게 다루는 범용 모델(GM
AI)'로 전환하자는 비전을 제시하는 Nature 논문입니다. 특히 이미지, EHR, 검사 결과, 유전체, 그래프,
텍스트를 함께 다루고, 라벨이 적어도 동작하는 모델을 목표로 한다는 점에서, 멀티모달 학습·비전-언어
모델·문서 이해·멀티모달 RAG에 관심 있는 학생에게 방향성을 주는 읽을거리입니다. 다만 이 메타데이터
만으로는 구체적 실험 설계나 성능 비교를 확인할 수 없으므로, '무엇을 주장하는가'와 '어떤 기술적 전
제에 기대는가'를 중심으로 읽는 것이 좋습니다.

## Why Read This Paper
- 의료 AI의 다음 단계로 제안되는 'generalist medical AI'라는 문제 설정을 이해할 수 있다.
- 멀티모달 학습 관점에서 의료 데이터의 결합 방식(이미지, 텍스트, EHR, 검사, 유전체 등)을 큰 그림으
로 볼 수 있다.
- 라벨이 부족한 상황에서 self-supervision과 대규모·다양한 데이터셋이 왜 핵심인지 논리적으로 따라갈
 수 있다.
- 모델 출력이 단순 분류가 아니라 자유 텍스트 설명, 음성 추천, 이미지 주석까지 확장된다는 점에서,
비전-언어/인스트럭션 계열 연구와 연결해 읽기 좋다.
```

```
## Recommended Prerequisites
- 멀티모달 모델의 기본 개념: 입력 모달리티가 다를 때 표현을 어떻게 맞추는지
- self-supervised learning의 목적과 라벨 효율성 개념
- 의료 AI에서 자주 쓰이는 데이터 유형(EHR, 의료영상, 임상 텍스트)의 기본 용어
- 분류 중심 모델과 생성/설명 중심 모델의 차이
- 의료 분야에서 모델 검증과 규제 이슈가 왜 중요한지에 대한 기본 감각

## Suggested Reading Order
- 1) 초록을 먼저 읽고, 이 논문의 핵심 명제를 한 문장으로 정리해 보세요: '의료 AI는 과제별 모델이
아니라 범용 의료 AI로 가야 한다.'
- 2) 본문 서론에서 왜 기존 접근이 부족한지, 그리고 GMAI가 어떤 문제를 해결하려는지 확인하세요.
- 3) 논문에서 제시하는 '가능한 응용'과 '필요한 기술적 능력/데이터셋'을 분리해서 읽으세요. 주장과
근거를 섞지 않는 것이 중요합니다.
- 4) 모델 입력으로 어떤 의료 모달리티를 상정하는지, 출력이 어떤 형태를 목표로 하는지 표로 정리해
보세요.
- 5) 마지막으로 규제·검증·데이터 수집 변화에 대한 논지를 읽고, 기술 제안이 실제 의료 시스템에 어떤
 파장을 가지는지 토론 질문으로 바꾸세요.

## What To Focus On
- GMAI라는 새 패러다임을 기존 medical AI와 어떻게 구분하는지
- 모델이 다룰 입력 모달리티의 범위가 왜 중요한지
- self-supervision이 의료 분야에서 갖는 의미와 기대효과
- ‘very little or no task-specific labelled data’라는 문구가 실제로 요구하는 전제
- 자유 텍스트 설명/음성 추천/이미지 주석 같은 출력이 왜 임상적 활용성과 연결되는지
- 저자들이 'high-impact potential applications'을 어떤 수준의 비전으로 제시하는지
- 규제와 검증이 기존 AI 디바이스 전략과 어떻게 충돌할 수 있다고 보는지
## Caution Points
- 이 메타데이터에는 구체적 실험 결과, 성능 수치, 비교 기준이 없습니다. 따라서 논문의 강점을 '검증
된 성능'으로 읽기보다 '비전과 문제정의'로 읽어야 합니다.
- 초록은 매우 포괄적이므로, 실제로 모든 모달리티를 하나의 모델이 다룬다는 의미인지, 혹은 개념적 제
안인지 본문에서 확인해야 합니다.
- ‘advanced medical reasoning abilities’는 중요한 주장지만, 메타데이터만으로는 이를 어떻게 입증했
는지 알 수 없습니다. 증거 수준을 본문에서 반드시 점검하세요.
- 의료 규제와 데이터 수집 변화에 대한 언급은 방향성 제시일 가능성이 크므로, 구체적 정책 제안인지
일반론인지 구분해서 읽어야 합니다.

## Comparison To Previously Read Papers
이전 읽은 논문 기록은 없지만, 사용자의 관심사와 비교하면 이 논문은 비전-언어 모델, 이미지-텍스트
정렬, visual instruction tuning, multimodal RAG와 매우 잘 맞습니다. 다만 일반적인 멀티모달 연구가
웹 스케일 텍스트-이미지에 초점을 두는 경우가 많다면, 이 논문은 의료 도메인에서의 모달리티 다양성과
 규제/검증 문제까지 함께 다룬다는 점이 차별점입니다. 따라서 '기술 방법'보다 '의료 문제 설정과 시스
템 수준 요구사항'을 읽는 연습용으로 적합합니다.


분석 결과 저장: runs\20260425_155543_foundation-models-for-generalist-medical-artificial-intellig_
analysis.md
```

## 8. 결론

본 프로젝트는 대학원생의 실제 연구 생활에서 자주 발생하는 문제, 즉 **읽을 논문을 고르는 병목**을 해결하기 위한 연구 보조 GPT 이다. 구현은 학술 API 검색, 점수 기반 후보 압축, 구조화 프롬프트, LLM 재정렬, 읽기 가이드 생성, fallback, 로그 저장을 결합한 하이브리드 구조로 이루어졌다.

무엇보다 중요한 점은 이 시스템이 강의에서 다룬 Prompt Engineering, LLM 의 제약, AI Design & Control, Responsible AI 개념을 억지 없이 실제 설계에 연결한다는 것이다. 따라서 본 프로젝트는 단순 데모를 넘어, **실제로 스터디 준비 과정에서 사용할 수 있는 연구 보조 파이프라인의 출발점**이라고 평가할 수 있다.